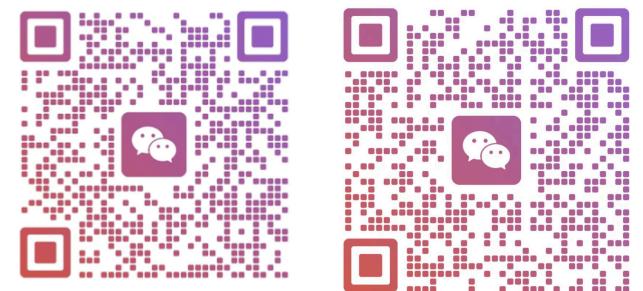


从轻量级到大模型： 构建鲁棒且可解释的ECG早期心梗识别模型

王佳、张海超
西交利物浦大学
2025年11月12日



王佳 (西交利物浦大学助理教授 博士生导师)

- 北京交通大学（本科）
- 瑞典皇家理工（硕士导师：庞智博）
- 香港理工大学（博士导师：曹建农）
- 基于数据驱动强化学习的决策系统

项目与资助：

24-27, PI, 用可控的机器学习研究, NSFC青年基金项目。

23-26, PI, 基于反事实因果的合规推荐系统研究, 江苏省高层次项目。

22-26, PI, 基于复杂系统大数据的视觉缺陷检测方法与研究, AI Empowerment Tech, 50万。

22-26, PI, 基于大数据分析的健康照明：方法与应用, 江苏天光白光电有限公司, 50万。

22-25, PI, 复杂系统多阶段大数据分析：方法与应用, 研究发展基金, 10万。



- 1 研究背景：AI与医学交叉的临床需求 ↗
- 2 数据不平衡：聚类增量学习 ↗
- 3 数据偏倚与公平性：因果推理 ↗
- 4 时序建模：基于Prompt的时间序列大模型 ↗
- 5 图像建模：光学压缩式ECG视觉表示 ↗
- 6 模型可解释性：反事实强化学习解释器 ↗

1. 研究背景：AI与医学交叉的临床需求

1.1 AMI诊断的“时间之困”

- 临床目标：急性心肌梗死（AMI）是全球致死率最高的单病种之一，早期识别直接决定抢救成功率
- 核心原则：“时间就是心肌”（Time is Muscle）
 - 从血管闭塞到心肌开始坏死，窗口期极短。
 - 临床决策的核心：“快”（速度）与“准”（精度）。
 - 目标：立即识别出需要紧急血运重建（Revascularization）的患者。
- 当前急诊胸痛分诊流程（Triage Flow）
 - 患者入院 -> 12导联ECG -> 抽血（等待心肌标志物）。
 - 这个流程在识别 STEMI（ST段抬高型心梗）时非常高效。

1.2 NSTEMI诊断的“灰色地带”

真正的瓶颈：非ST段抬高型心梗（NSTEMI）患者

- **STEMI (路径清晰)**

- **ECG表现：** 明确的ST段抬高。
- **诊断：** 确诊闭塞。
- **临床路径：** 立即送入导管室，进行血运重建
- **AI价值：** 锦上添花。

- **NSTEMI (灰色地带)**

- **ECG表现：** ST段不抬高，表现不特异（T波倒置，ST段压低等）。
- **诊断：** 无法立即确认闭塞。
- **AI价值：** 雪中送炭。

1.3 AI的机遇：从“ECG判读”到“ECG虚拟冠脉造影”

临床的核心痛点：

“在ST段未抬高的患者中，隐藏着大量同样致命的急性冠脉闭塞 (Occlusion)，而我们无法仅凭ECG快速识别。”

- **人眼局限：** 依赖“ST段抬高”这一“强特征”，易忽略NSTEMI中微弱、高维的病理模式。
- **AI的潜力：**
 - ECG是高维时序信号，蕴含远超形态学的信息。
 - AI（特别是深度学习）擅长从12导联的复杂关联中，学习人眼无法感知的“微弱特征” (Subtle Patterns)。

1.4 我们的研究目标：构建“ECG虚拟冠脉造影”

利用2800例ECG及“金标准”造影数据，训练一个端到端模型，实现：

1. 阶段一：分诊

- 是否需要做冠脉造影

2. 阶段二：ECG细粒度对齐到冠脉造影

- 闭塞定位 (Localization): 哪根血管 (LAD/LCx/RCA) ?
- 狹窄定量 (Quantification): 狹窄率是多少 (是否 > 70%) ?

2. 数据不平衡：聚类增量学习

2.1 挑战：临床数据的“天然鸿沟”

- 现状：
 - 多数类 (Majority): 大量 NSTEMI–非闭塞 患者 (如狭窄<50%)。
 - 少数类 (Minority): 少量我们真正要找的 NSTEMI–急性闭塞 患者 (如狭窄>70%)。
- AI建模的“经典陷阱”：
 - 模型会“躺平” (Get Lazy): AI为了追求90%的“总准确率”，会放弃学习那10%的少数类。
 - 临床后果：产生一个“看似准确”但对所有高危心梗患者全部漏诊的“废物模型”。

2.2 常规解法：“人工合成”病例 (SMOTE)

- 方法：**通过算法“复制”或“合成”更多的高危闭塞病例，强行让数据1:1平衡。
- 致命缺陷：**
 - 模糊边界：**如果制造的样本在“临界”病例周围，反而让模型更难区分结果。
 - 引入噪声：**合成的ECG波形可能不符合生理学逻辑，成为“脏数据”。

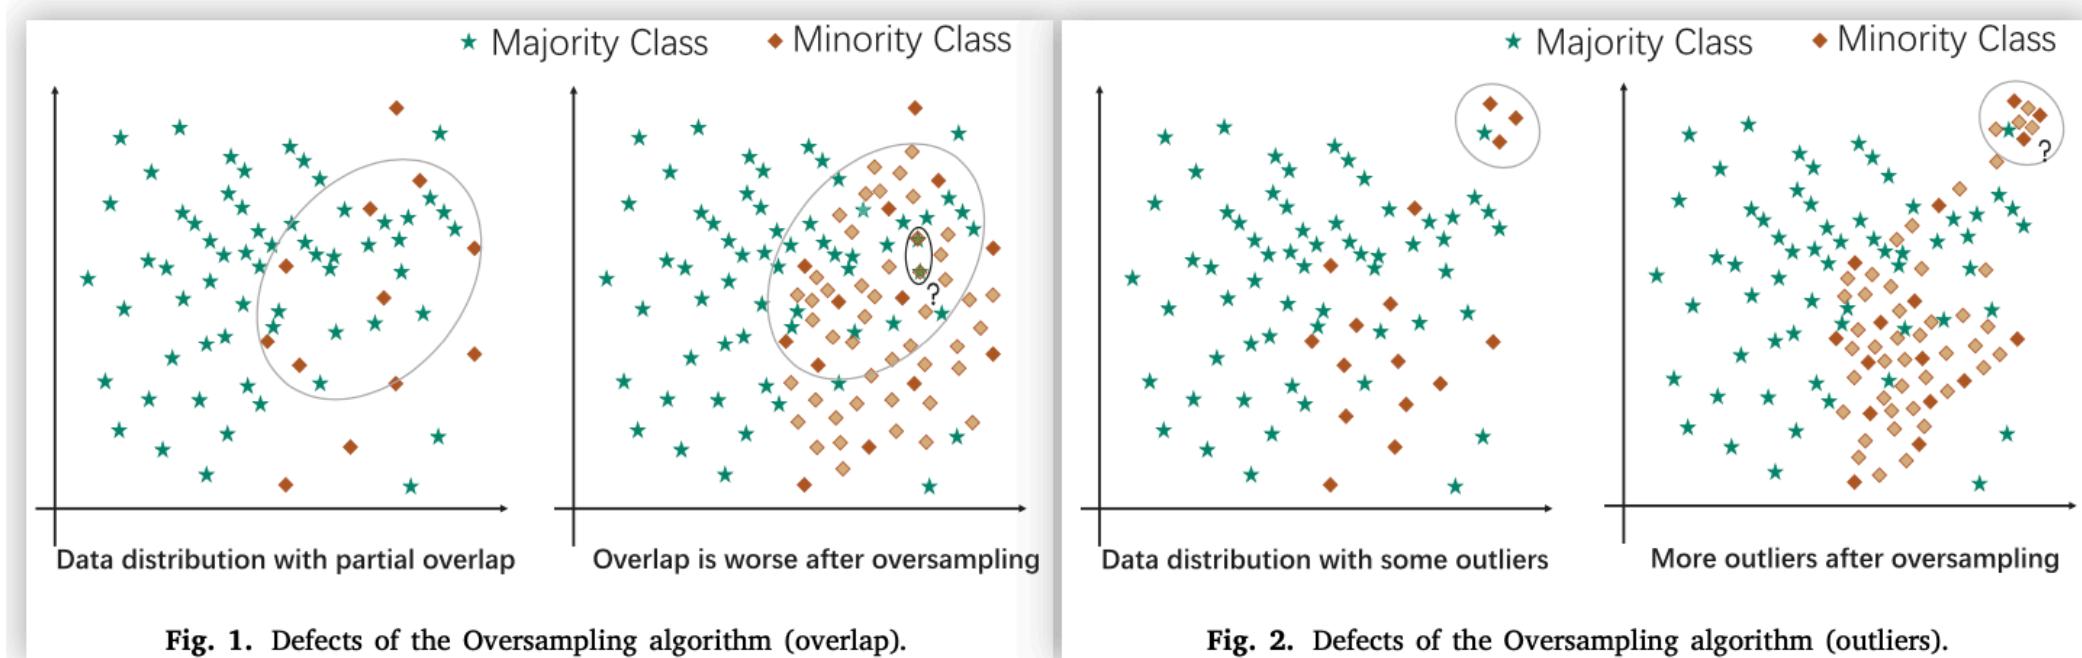


Fig. 1. Defects of the Oversampling algorithm (overlap).

Fig. 2. Defects of the Oversampling algorithm (outliers).

2.3 我们的对策：智能分群 + 递进式学习

我们不“人工合成”噪声，而是“智能拆解”数据（借鉴 DRIL 框架）

- **步骤一 (DR Step): “两步聚类” – 智能拆分多数类**

- **做法：** 我们使用“两步聚类法”(Two-Step Cluster)，将海量的“非闭塞”患者（多数类）自动分为几个有代表性的“**亚群**”(Sub-groups)。
- **比喻：** 不再是‘一整群低风险’，而是‘**亚群1**: T波轻微倒置’、‘**亚群2**: ST段轻微压低’、‘**亚群3**: 正常ECG’...

- **步骤二 (IL Step): “增量学习” – 逐个击破**

- **做法：** 将“急性闭塞”病例（少数类）**依次**与每个“非闭塞亚群”组合，分阶段训练模型。
- **临床获益：** 强迫模型在**所有类型的“干扰背景”下**，都能精确认别出“高危闭塞”的共同特征，显著提高模型的鲁棒性和泛化能力。

2.4 方法框架图

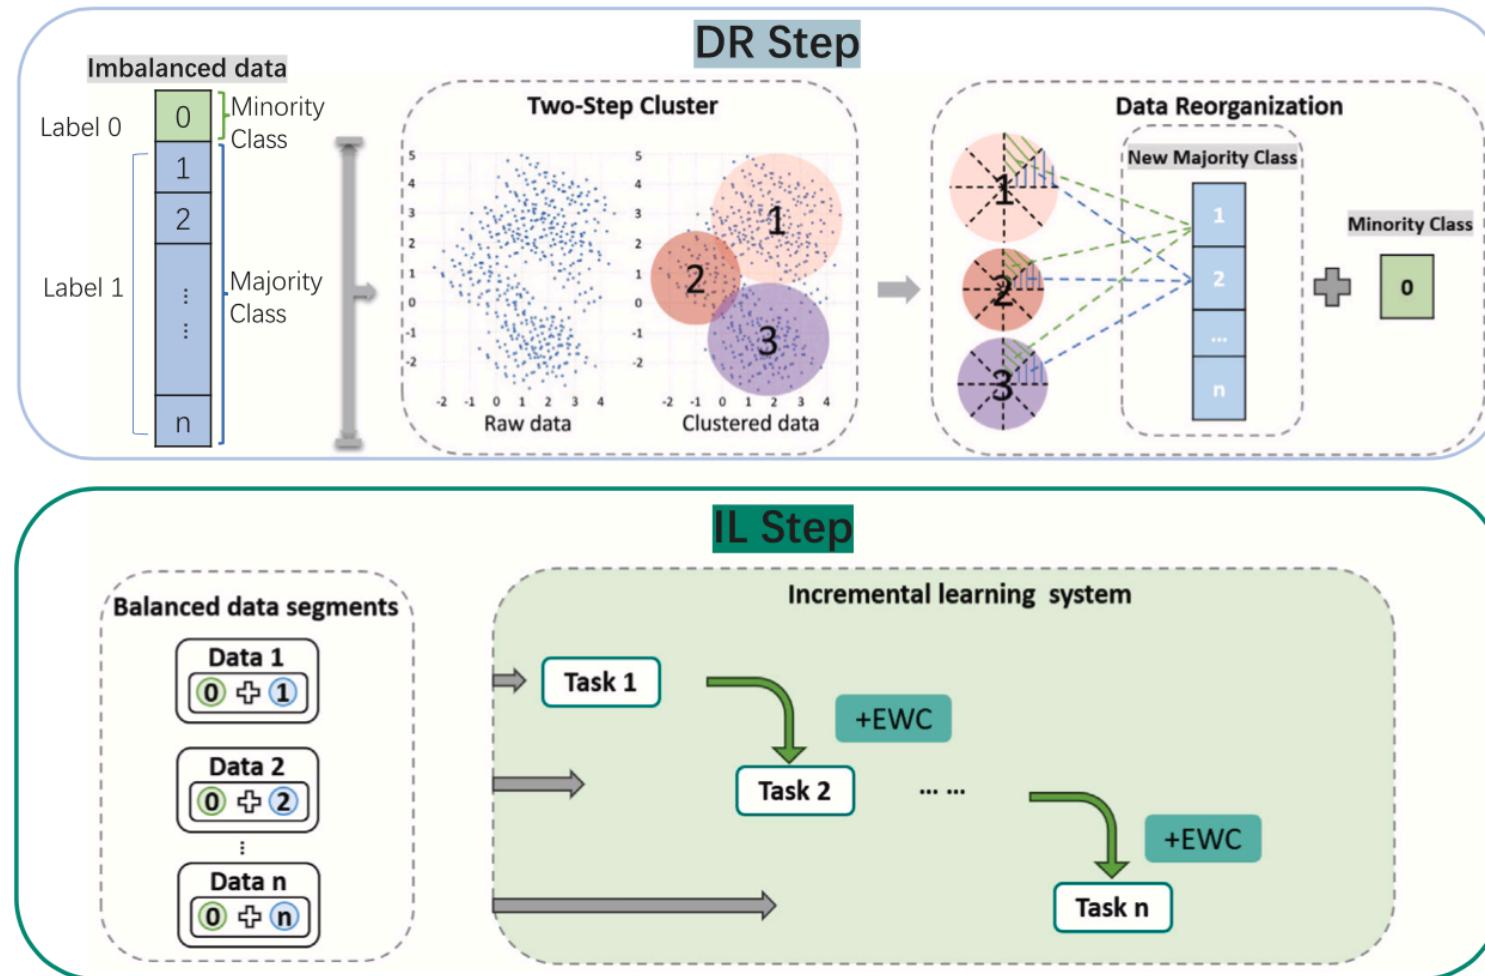


Fig. 4. Framework overview of the DRIL methodology.

3. 数据偏倚与公平性：因果推理

3.1 挑战：算法偏见的“伪装”

问题：AI模型会“投机取巧”，学习临床“捷径” (Shortcuts)

我们的数据中，不可避免地存在混淆变量 (Confounders)，如年龄、性别、既往病史等。

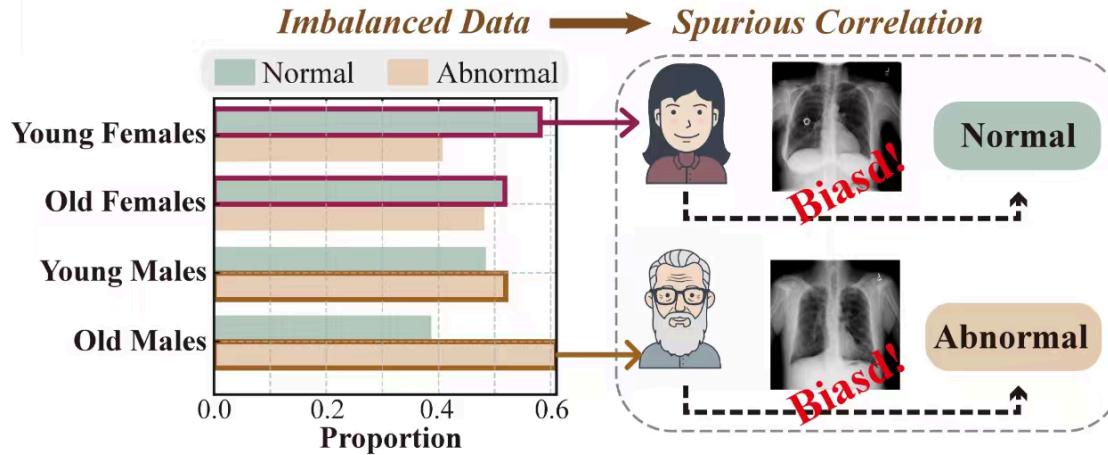
- **常规AI的陷阱：学习“伪相关性”**

- 模型会发现一个“捷径”：“70岁以上男性” (Z) 这个特征，与 “发生心梗” (Y) 高度相关。
- 它会**放弃学习**复杂的 ECG波形 (X)，转而依赖 年龄/性别 (Z) 来进行预测。

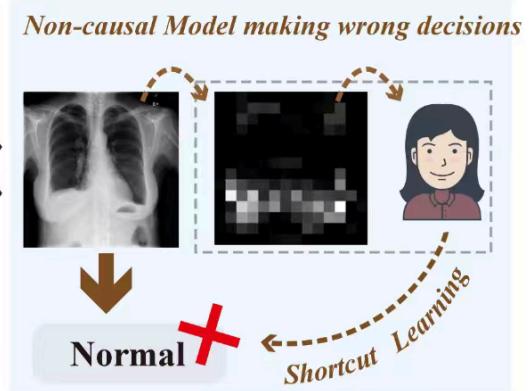
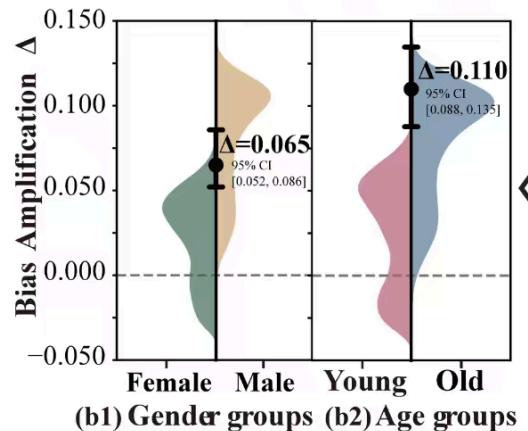
3.2 临床的灾难性后果

1. **漏诊 (False Negative):** 面对一个**40岁的女性**（不符合“捷径”特征），即使其ECG有典型闭塞波形，模型也可能将其误判为“低风险”。
 2. **误诊 (False Positive):** 面对一个**70岁的男性**（符合“捷径”特征），即使其ECG正常，模型也可能过度敏感，将其判为“高风险”。
- **我们的目标：** 斩断“捷径”，强迫模型从ECG信号本身进行因果推断。

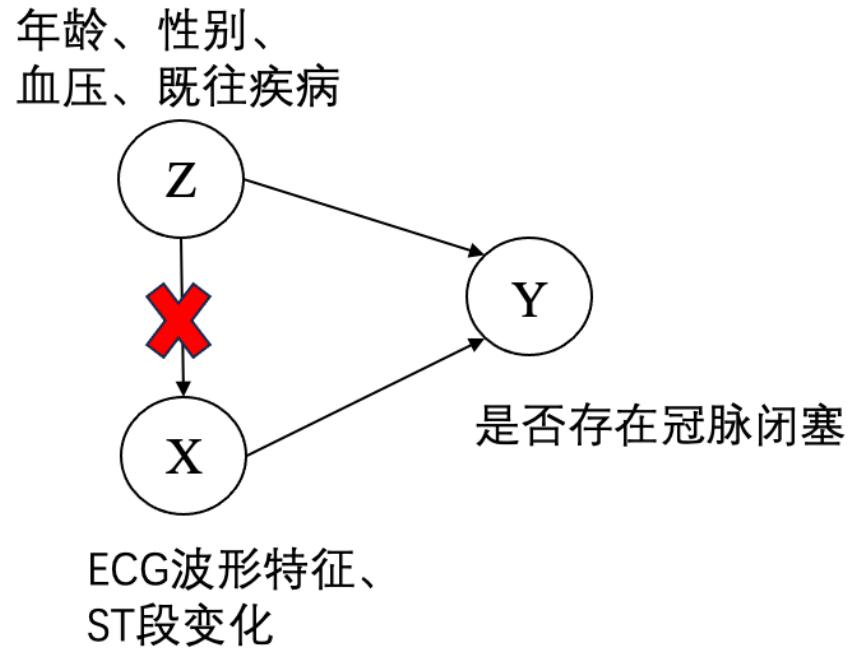
(a) Dataset Bias.



(b) Models amplify the bias.



3.3 我们的对手：“后门路径” (Back-Door Path)



AI模型有两条路径可以“抄作业”：

1. 真实诊断路径 (Causal Path)

- $Z \rightarrow X \rightarrow Y$
- ECG波形 **导致/反映** 冠脉闭塞。
- **这是我们希望AI学习的唯一路径。**

2. 虚假偏倚路径 (Back-Door Path)

- $Z \leftarrow X \rightarrow Y$
- 年龄(Z) 既影响 ECG波形(X)，也影响 冠脉闭塞(Y)。
- 这在X和Y之间建立了一条“虚假”的统计关联。**(图中红色X标记的路径就是这条“后门”的关键干扰)**

3.4 我们的对策：“后门调整” (Back-Door Adjustment)

目标：强迫AI忽略“虚假路径”，只学习“真实路径”

- **理念：** 我们不能直接计算 $P(Y|X)$ ，因为这个概率被年龄(Z)污染了。我们必须计算 $P(Y|do(X))$ —— 即在“干预”了ECG后，闭塞发生的真实概率。
- **“后门调整”的临床转译：**

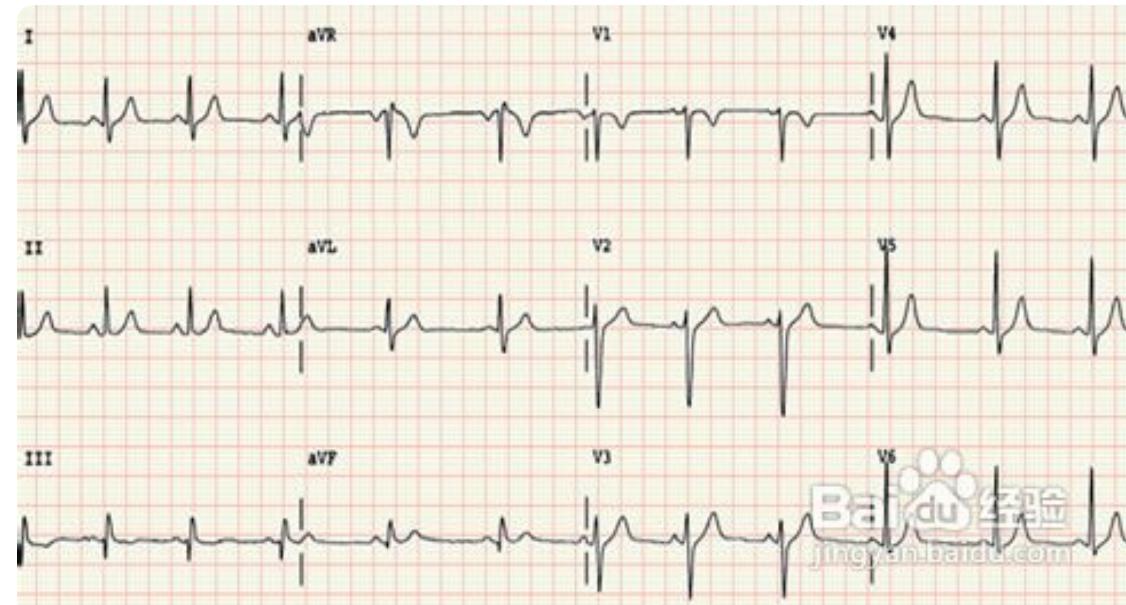
我们通过对混淆变量 (Z) 进行统计分层，强迫模型回答一个更精确、更公平的临床问题：
**“假设在年龄、性别、血压(Z)完全相同的两个患者中，
ECG波形(X)的‘何种差异’，
真正导致了其中一人发生闭塞(Y)？”**

4. 时序建模：基于Prompt的时间序列大模型

ECG的双重身份 (视角A: 时序信号)

ECG的本质: 12导联的高维、非平稳时序信号

- **数据特征:** 12通道 (导联) 高度耦合, 10秒 @ 500Hz 采样 = **60,000个数据点**。
- **病理特征:**
 - **局部 (Local):** 单个导联的P–QRS–T波形态、ST段偏移。
 - **全局 (Global):** 12个导联间的协同变化、长时依赖 (Long–Range Dependency)。



建模的“双重困境”

1. 轻量级模型 (1D-CNN/LSTM):

- “管中窥豹”: 擅长捕捉**局部**形态, 但易丢失**全局**信息。
- **临床局限**: 无法有效建模12个导联间的局部协同变化。

2. 重量级模型 (Transformer):

- “**全局视野**”: 自注意力机制 (Self-Attention) 擅长捕捉全局依赖。
- **挑战**: 60,000个点的序列过长, 计算量巨大, 且对局部噪声敏感。

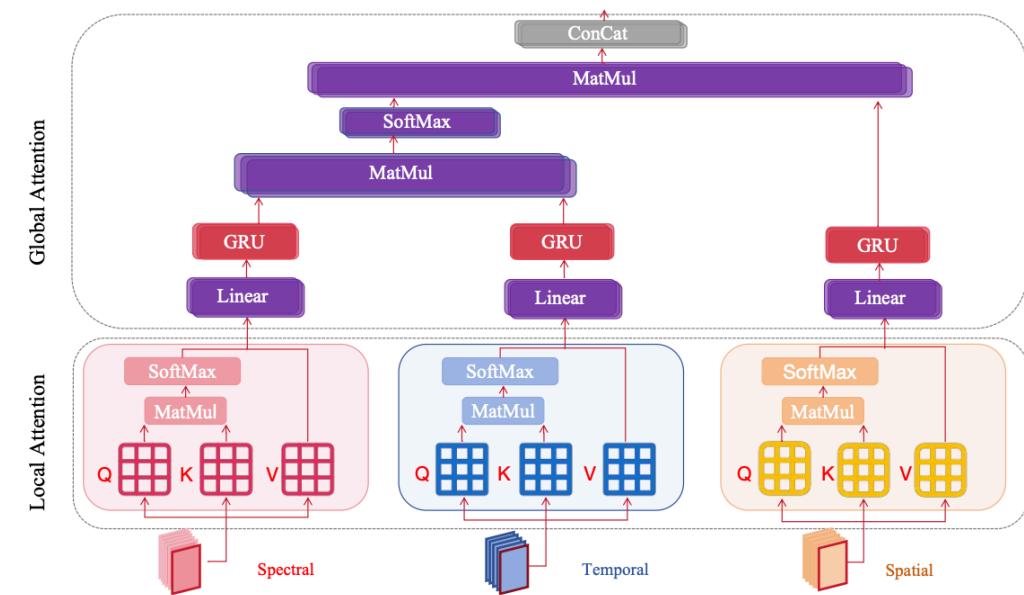
“全局-局部”融合框架

- 局部特征 (Local Attention)

- 轻量级 (CNN): 快速扫描12导联，捕捉局部的形态特征（如QRS增宽、ST段偏移、T波倒置）。
- 临床意义: 识别独立的“病理波形”。

- 全局特征 (Global Attention):

- 重量级 (Transformer): 整合所有“局部”信息，分析它们在全局（跨12导联）的协同关系。
- 临床意义: 识别“心梗模式”（如下壁、前间壁）。



解决“6万个数据点”的算力与噪声挑战

问题： 10秒的ECG（60,000+数据点）对AI来说是“天文数字”，直接处理会“算不动”且“被噪声淹没”。

我们的对策（借鉴 APaLLM 论文）：先“提纯”信号，再“打包”读取。

1. 信号提纯 (Decomposition)

我们首先将原始时序信号分解为三部分：

- **趋势项 (T)**: 整体的大趋势。
- **季节项 (S)**: 周期性的变化信号。
- **残差项 (R)**: T+S与真实信号的残差项。

获益： 我们只让AI分析“R项”。这就像在嘈杂的房间里只听心跳声，极大排除了干扰。

2. 打包读取 (Patching)

AI不会“一个点一个点”地读6万次，而是“一段一段”地读。

- **做法：** 我们将“纯净信号”打包成 **Patches**（小片段）。
- **类比：** AI不再是“逐字阅读”，而是“逐词阅读”。

获益： 序列长度从60,000急剧缩短到几百，AI可以**高效地看到全局**，理解QRS波、T波等“波形模式”。

5. 图像建模：光学压缩式ECG视觉表示

ECG的双重身份 (视角B: 图像信号)

一个反直觉的思路：为什么不直接“看图”？

- 传统观念：将ECG图（12导联波形）视为图像，是“信息丢失”的。
- 大模型（VLM）的新观念：视觉是一种高效的“信息压缩”。
- 临床类比：
 - 60,000个点的时序数据，就像一本6万字的“流水账”。
 - 1张12导联ECG图像，就像一张“总结图表”。
- AI的进化：
 - 以前的AI（轻量级模型）看不懂图，只能处理“流水账”。
 - 现在的视觉大模型（VLM）更擅长“看图”，能一眼识别出图表中的“关键模式”。

“光学压缩”的ECG视觉表示

借鉴 DeepSeek-OCR 论文：用“少量视觉Token”压缩“海量文本”

- DeepSeek-OCR 的核心洞察：

- VLM（视觉大模型）可以用极少数的“视觉Token”（如100个），来完美解码（Optical Character Recognition）一张包含数千个“文本Token”的复杂图像。
- 这证明了“光学2D映射”是一种极高效率的信息压缩。

- 我们的临床转译与应用：

- “海量文本” (1000+ Tokens) → “ECG原始信号” (60,000+ Points)
- “压缩图像” (100 Tokens) → “12导联ECG图” (用少量视觉Token表示)

我们不直接处理60,000个点，而是处理压缩后的“视觉ECG图”。

“全局-局部”视觉编码器

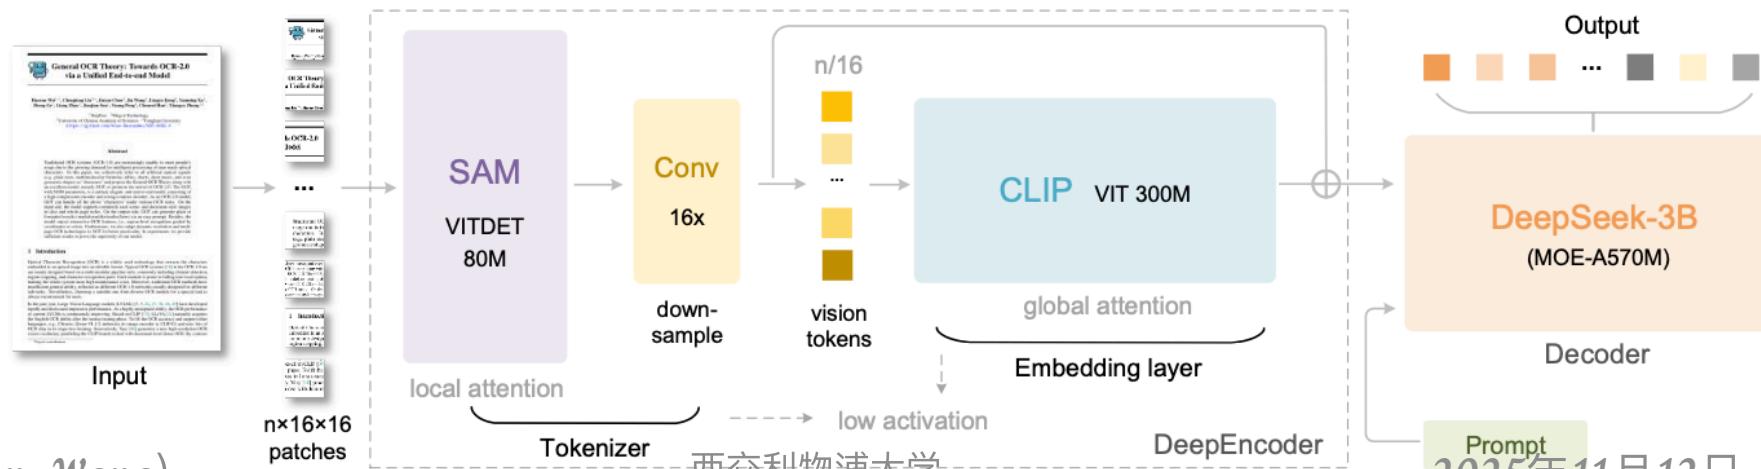
为了让AI“看懂”这张高分辨率的ECG图，我们采用了类似的“全局-局部”视觉框架：

1. 局部感知 (Local Attention)

- **模型：**窗口注意力 (Window Attention)。
- **任务：**像放大镜一样，精细“感知”ECG图上的**局部细节** (如单个ST段的形态、T波是否倒置)。

2. 压缩与全局认知 (Global Attention)

- **模型：**16x压缩器 + 全局注意力。
- **任务：**将“局部细节”压缩后，进行“全局认知”，理解12个导联在图像上的**空间布局和协同关系** (如“胸前导联的集体抬高”)。



6. 模型可解释性：反事实强化学习解释器

AI的“黑盒”——如何信任它？

最大的临床障碍：AI如何取得医生的信任？

- **问题：**无论模型（轻量级或大模型）预测得多准，如果它只是一个“黑盒”，临床医生就无法信任它，更不敢基于它的建议（如“立即手术”）采取行动。
- **临床医生的核心疑问：**
 - i. “你凭什么这么说？”（归因, Attribution）
 - AI是根据哪个导联、哪个波形的微小变化，做出的“NSTEMI–急性闭塞”判断？
 - ii. “如果.....会怎样？”（反事实, Counterfactual）
 - “如果V2导联的T波没有这个微小抬高，你还会认为是闭塞吗？”
 - “我需要将ECG改变多少，才能让你的模型改变诊断？”

我们的目标：AI不仅要提供答案，更要提供“可操作的证据”。

反事实解释器 (Counterfactual)

我们引入一个AI“侦探”(RELAX)，让它来审查“黑盒模型”的工作。

这个“侦探”的任务是玩一个“What-if”游戏：

“我需要对这份‘高危心梗’ECG做‘多小’的改动，才能让‘黑盒模型’将其改判为‘低风险’？”

- 临床解读：
 - i. 输入 (Original Example): 一份被“黑盒模型”诊断为“高危闭塞”的ECG。
 - ii. “侦探” (Counterfactual Generator): RELAX 解释器开始工作，它尝试“最小程度”地修改ECG波形（如“降低V3的T波”、“拉平aVL的ST段”...）。
 - iii. 输出 (Optimal Counterfactual): “侦探”找到了一个“最小修改方案”（比如：仅将V3的T波幅度降低 $0.2mV$ ），这份新ECG就被“黑盒模型”改判为“低风险”了。
- 最终结论：这份“反事实”报告精确地告诉了医生——V3导联的T波，就是导致模型做出“高危”诊断的“罪魁祸首”。

反事实解释器框架图

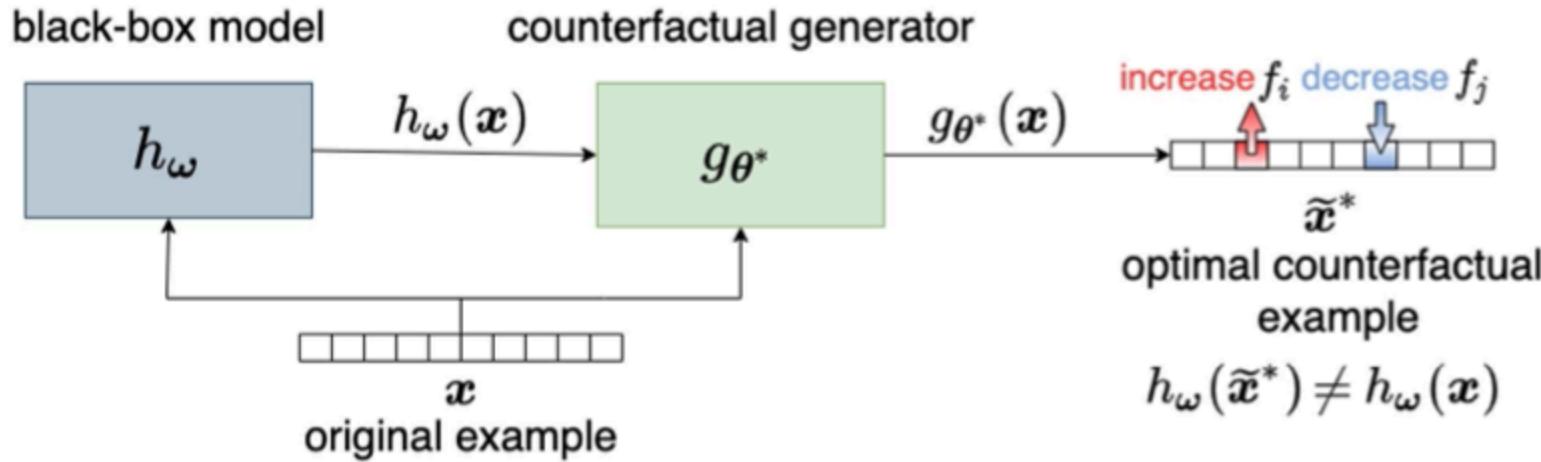


Fig. 1. Overview of a generic counterfactual explainer.

Chen, Z., et al. Explain the Explainer: Interpreting Model–Agnostic Counterfactual Explanations of a Deep Reinforcement Learning Agent. IEEE Transactions on Artificial Intelligence.

“解释”我们的“侦探”

问题： RELAX “侦探”本身也是一个复杂AI（深度神经网络），它不也是“黑盒”吗？

答案： 是的，所以我们更进一步——“**解释这个解释器**”。

我们使用“**知识蒸馏**”技术，将这个“侦探”的复杂“大脑”

.....“蒸馏”成一个医生能看懂的“简单决策流程图”（Distilled Decision Tree Policy）。

- **临床价值：**

- 我们最终交付给医生的，**不是另一个黑盒**。
- 而是这样一个**透明的、可被验证的“IF-THEN”逻辑**：

- “**IF** V2导联T波 > 0.1mV (且未被修改过)..."
- “**THEN** ‘侦探’的首选动作是：修改 **V2导联**。”

- **最终：** 整个诊断（黑盒模型）和解释（侦探模型）的流程，都变得**完全透明、可信赖**。

欢迎交流 ~



- 邮箱: jia.wang02@xjtlu.edu.cn
- 欢迎老师学术交流
- 欢迎学生RA访问